

Relatório — Atividade 02: pipeline de dados de teses e dissertações de Saúde

Grupo 7: Eduardo Melo, Otávio França e Ygor Moraes

Disciplina: Tópicos em Inteligência Artificial (DC/CCN072) — UFPI — Prof. Raimundo Santos Moura

Data: 25/09/2026

Repositório: <https://github.com/ygormoraes7/LLM-Coleta-Atividade2>

Código: repositório bdttd-corpus. O protocolo de coleta completo está em docs/PROTOCOLO_DE_COLETA.md.

Resumo

O grupo construiu um pipeline em quatro camadas (Raw → Staging → Processed → Curated). Ele coleta teses e dissertações de Saúde e as transforma em dados para pré-treino contínuo, fine-tuning, RAG e avaliação de modelos de linguagem em português.

- **Coleta:** 25.338 PDFs de acesso aberto, de 67 instituições, pelo OAI-PMH da UFMG e pelo inventário da BDTD (183.718 fichas). A coleta respeita o robots.txt pela letra e pelo espírito, no ritmo de 1 requisição a cada 3 segundos por repositório. A fila das instituições autorizadas acabou; a meta de 50 mil não foi atingida, como a conta prévia indicava (~26 mil).
- **Corpus tratado:** todos os PDFs coletados foram tratados (25.237 com texto extraído). Resultou em 21.515 documentos de 67 instituições, com 461,9 milhões de palavras e 35.891 dados pessoais mascarados.
- **Produtos:** pré-treino com 21.515 documentos, 3.689 pares de fine-tuning, 1.000.330 trechos para RAG e 775 itens de benchmark. A verificação final de dados pessoais encontrou 0 ocorrências.
- **Qualidade:** 164 testes automáticos e 24 defeitos corrigidos, a maioria achada por leitura manual dos dados.
- **Limites:** o corpus é o que cabe no protocolo de coleta. A busca por outras fontes além da BDTD não abriu caminho (seção 8).

1. Enunciado e onde está no código

Item pedido	Implementação	Código
Crawler da BDTD para Saúde	inventário por OAI-PMH e pelo inventário da BDTD; página do item até o PDF; download por instituição	src/raw/
Arquitetura em camadas	Raw → Staging → Processed → Curated; nenhuma camada altera a anterior	src/, run_pipeline.py
Tratamento na Processed	extração com OCR, normalização, padronização, anonimização, qualidade, escopo e deduplicação	src/processed/
Produtos na Curated	pré-treino, fine-tuning, RAG, benchmarks e verificação de dados pessoais	src/curated/

As decisões de projeto (fontes, filtros, ritmo, limiares) ficam em config/config.yaml. Cada camada grava um relatório com entradas, saídas, métricas e falhas em data/reports/saude/.

2. Arquitetura

FONTES	OAI-PMH da UFMG + inventário da BDTD
— RAW	metadado cru e PDF original, sem alteração
— STAGING	tabelas Parquet, codificação corrigida, tipo real do arquivo
— PROCESSED	extração, limpeza, padronização, anonimização, filtros, dedup
— CURATED	pré-treino, fine-tuning, RAG, benchmarks, verificação de PII

Nenhuma camada modifica a anterior. Por isso, corrigir um filtro exige apenas reprocessar a partir da camada afetada, sem baixar nada de novo.

```
python -m pytest # testes
python preflight.py # verificação antes de coletar
python -m src.raw.inventario robots # evidência de robots.txt por domínio
python -m src.raw.inventario bdttd_csv # candidatos do inventário da BDTD
python run_pipeline.py --camadas raw # download
python run_pipeline.py --camadas staging processed curated
```

3. Coleta (Raw)

3.1 Fontes

A BDTD guarda as fichas dos trabalhos, mas o PDF fica no repositório de cada universidade. Por isso a coleta tem dois passos: montar a lista de trabalhos e, para cada um, achar o PDF no repositório de origem.

- **OAI-PMH da UFMG** (conjunto de Ciências da Saúde). A colheita é fatiada em janelas de datas, porque a paginação profunda do servidor falha. Uma janela que falha é dividida ao meio; se não se recuperar, a perda é declarada.
- **Inventário da BDTD**, montado pelo grupo pela API da BDTD (183.718 fichas). A busca da interface, proibida a robôs, não é usada. A API tem limites que exigiram fatiar a consulta: a paginação para na página 10 e as facetadas devolvem no máximo 30 valores. Sobre o inventário aplicam-se os filtros do projeto: acesso aberto; escopo de Saúde por radicais ("odontolog" pega "odontológico"); e exclusão de zootecnia e veterinária por palavra inteira. Na coleta final não há limite por instituição: 58.491 candidatos no escopo.

3.2 Da página do item ao PDF

O coletor tenta, nesta ordem:

1. a metatag `citation_pdf_url`;
2. os links de arquivo da página;
3. o visualizador embutido em `<object type="application/pdf">`, usado pelo SidUece da UECE;
4. no Tainacan (UNB), o campo `uri-handle` do item, lido pela API do próprio Tainacan, que aponta para o DSpace antigo onde o PDF está;
5. nos repositórios DSpace 7 que entregam a página sem links, a API REST do próprio repositório, com o endereço lido de `assets/config.json`.

O coletor também corrige endereços internos publicados por engano, como `localhost` ou IP com porta 4000. Só grava arquivos que começam com `%PDF` e têm até 120 MB. O download é retomável: um PDF que já está no disco não gera nova requisição.

3.3 Conduta de rede

Regra	Implementação
Identificação	User-Agent com projeto, instituição e e-mail de contato
Ritmo	1 requisição a cada 3 s por repositório, ou o Crawl-delay, se maior; até 24 instituições em paralelo, sem acelerar nenhum domínio
robots.txt	respeitado em todos os caminhos de rede e em cada redirecionamento
Letra e espírito	fica fora o domínio que veta robôs de IA pelo nome, que responde com desafio anti-robô (inclusive o da plataforma Sophia, na UNICAMP) ou que bloqueia o nosso agente. A checagem é feita antes da coleta e, nos links de handle, no domínio final
Crítérios de parada	disjuntor por instituição (erro acima de 30% após 20 tentativas, ou 20 falhas de rede seguidas); na colheita OAI, 5 falhas seguidas
Antes de coletar	testes e preflight, que bloqueiam a coleta sem evidência de robots.txt por domínio ou com ritmo acima do protocolo
TLS	verificação de certificado nunca desligada

4. Staging

A Staging converte o JSONL cru em quatro tabelas Parquet (documentos, autores, assuntos e arquivos), corrige a codificação, confere o tipo real de cada arquivo pelos primeiros bytes e valida a integridade. Nada é descartado nessa camada. Na última execução, foram 38.134 fichas, 25.324 delas com arquivo, de 95 instituições; os 14 arquivos sem ficha atual foram apenas registrados.

5. Tratamento (Processed)

As etapas seguem esta ordem: extração → normalização → anonimização → qualidade → escopo → deduplicação. A ordem importa: filtrar antes de normalizar reprova documento com codificação quebrada, e anonimizar antes de normalizar faz o detector de CPF errar.

- **Extração:** PyMuPDF, com OCR (Tesseract, português) quando a maioria das páginas é imagem.
- **Normalização:** codificação (ftfy), Unicode NFC, ligaduras, cabeçalhos e rodapés repetidos, números de página e hifenização. Também corta tudo antes do RESUMO e os anexos.
- **Padronização:** idioma em código ISO, tipo como "dissertação de mestrado" ou "tese de doutorado" e ano como inteiro, com o valor original preservado.
- **Anonimização** de dados de terceiros no texto, no título e no resumo. Autor e orientador não são mascarados, porque são dado bibliográfico público.

Detector	Regra
E-mail e perfil de rede social	padrão textual
CPF, CNPJ, título de eleitor, PIS/PASEP e cartão SUS	só com dígito verificador válido
Telefone	DDD válido, fixo começando de 2 a 5, celular com 9; intervalo de anos recusado

Detector	Regra
CEP e RG	formato; RG com 7 a 10 dígitos
Links, DOI e ORCID	protegidos dos detectores numéricos

Cada máscara é registrada com o trecho em volta já mascarado. A precisão foi medida recuperando o valor por trás de cada máscara: ~1.900 eram falsas (DOI e ORCID tomados por documento, nome de gene tomado por placa) e foram eliminadas.

- **Qualidade:** heurísticas no estilo Gopher/RefinedWeb, calibradas para tese em português: proporção de texto, símbolos, stopwords, linhas repetidas e idioma.
- **Escopo:** exclusão de zootecnia e veterinária por palavra inteira, com uma lista de expressões permitidas, como "pé equino" e "soro fetal bovino".
- **Deduplicação:** exata (SHA-256) e aproximada (MinHash com LSH, Jaccard a partir de 0,80).

6. Produtos (Curated)

Produto	Formato	Uso
Pré-treino	JSONL com id, texto e metadados	pré-treino continuado de modelo existente
Fine-tuning	JSONL com mensagens e metadados	seguir instruções
RAG	Parquet, trechos de 500 palavras com metadados	busca com citação da fonte
Benchmark	recuperação, múltipla escolha e perplexidade	avaliação

- Treino, validação e teste são divididos por autor e programa, e o treino é descontaminado contra a avaliação.
- Os pares de fine-tuning saem de campos do próprio documento (título, resumo, palavras-chave e introdução), sem texto gerado por modelo. Texto em inglês não entra.
- A **verificação final de dados pessoais** varre todos os produtos e interrompe o pipeline com erro se encontrar qualquer ocorrência.
- Os benchmarks medem recuperação sobre o acervo, não conhecimento de Saúde.

7. Verificação de qualidade

O projeto tem **164 testes automáticos** (python -m pytest), que não acessam a rede nem os dados reais. Cada defeito corrigido ganhou um teste com o caso real que o revelou. A cada reprocessamento, o grupo leu textos tratados, pares de fine-tuning e amostras das máscaras de dados pessoais. No total, 24 defeitos foram corrigidos; os principais estão abaixo.

Área	Defeito	Correção
Escopo	teses de zootecnia no corpus e, no sentido oposto, 10 teses de Saúde excluídas por "saneamento" ou "pé equino"	exclusão por palavra inteira, com todas as flexões e expressões permitidas
Anonimização	~1.900 máscaras falsas sobre DOI, ORCID e nomes de gene	dígito verificador e proteção de links

Área	Defeito	Correção
Anonimização	telefone real quebrado em linha escapava; foi achado porque a verificação final parou o pipeline	quebra de linha aceita depois do DDD
Fine-tuning	resposta copiada na pergunta (186 pares) e, depois, abstract em inglês no lugar do trecho (109 pares)	trecho tirado da introdução e trava de idioma
Direitos	16 documentos de acesso restrito quase entraram no corpus	filtro de acesso aberto em todos os caminhos
Coleta	repositórios DSpace 7 sem PDF localizável e endereços internos publicados	API REST com endereço do config.json e troca do endereço interno
Coleta	UNB (Tainacan) e UECE (SidUece) sem PDF localizável; página de desafio da UNICAMP contada como "PDF não localizado"	salto pelo <code>uri-handle</code> do Tainacan, leitura do <code><object></code> embutido e detecção do desafio anti-robô
Coleta	paralelismo travava num mesmo domínio; o disjuntor cortava instituições boas ao retomar	paralelismo por instituição e disjuntor com histórico
Processamento	o RAG estourava a memória; texto de rodada anterior era reaprovaado	gravação em lotes e Processed restrita ao Staging atual

8. Incidentes e perdas

Evento	O que houve	Decisão
Janela de datas da UFMG (fevereiro a junho de 2026)	o servidor responde HTTP 500; dos 755 registros, 235 foram recuperados	~520 registros declarados como perdidos
Piloto do inventário (UFRN, UFPR, Fiocruz)	0 de 180 PDFs, por variações de DSpace 7 e pelo servidor de handles da UFPR fora do ar	coletor corrigido (119 de 120 na repetição); UFPR fora
robots.txt de 76 domínios do inventário	23.993 dos 58.491 candidatos ficam fora: inacessibilidade (11.154), HTTP 403, 468 ou 5xx (8.193), veto a robôs de IA (4.413), bloqueio total (187) e desafio anti-robô (46)	34.498 candidatos autorizados
Disjuntor na coleta em escala	26 instituições cortadas na primeira execução	7 defeitos do coletor corrigidos; instituições com falha confirmada (certificado inválido, handle fora do ar, desafio anti-robô, links quebrados) suspensas sem nenhuma requisição (23 hoje)
Fiocruz (14/09)	o repositório parou de responder depois de 18 downloads; 376 falhas seguidas até o corte	suspensa; o disjuntor passou a cortar também por 20 falhas de rede seguidas
Reverificação das suspensas (16/09)	UNB corrigida (861 de 870 PDFs); UECE tem só 8 de 20, porque boa parte dos registros não tem arquivo digital; UNICAMP responde com desafio anti-robô por token; UFRRJ devolve HTTP 403 de forma intermitente	UNB reabilitada; UECE, UNICAMP e UFRRJ seguem suspensas

Evento	O que houve	Decisão
Outras fontes	o robots.txt do Oasisbr veta pelo nome ClaudeBot e outros robôs de IA; o Catálogo de Teses da CAPES cobre só 2021–2024, sem link para o PDF	Oasisbr descartado pelo critério da letra e do espírito; CAPES sem uso
Fim da fila	a fila das instituições autorizadas esgotou em 24.443 PDFs (15/09); meta de 50 mil não atingida	coleta encerrada em 25.338 PDFs

9. Resultados

9.1 Coleta

Etapas	PDFs
UFMG pelo OAI-PMH	3.477
Piloto do inventário e coleta até 15 mil	11.621
Coleta até 50 mil pelo inventário (fila esgotada)	9.345
Reabilitação de instituições (UNB 881, UECE 8)	889
Retentativas do Raw final	6
Total	25.338

Os PDFs vêm de 67 instituições. Além da UFMG, as que mais contribuíram foram UFRN (3.483), UFG (1.665), UFSCar (1.598), UFU (1.461), UEM (1.274), UNESP (1.242), UFS (1.052), UFES (1.036), UFMA (953), UEL (891) e UNB (881).

9.2 Corpus tratado

Todos os PDFs coletados passaram pela Processad, sem amostra (a opção `processed.amostra` do `config.yaml` ficou em 0).

Métrica	Valor
PDFs tratados	25.237 (87 sem texto: 75 com falha de leitura do PDF e 12 sem texto suficiente)
Documentos no corpus	21.515 de 67 instituições: UFMG 2.845 e 18.670 das demais
Aprovação	82% na UFMG e 86% nas demais instituições
Palavras	461,9 milhões (mediana de 17.681 por documento) e 2,25 milhões de páginas
Período	1903 a 2026
Reprovados	3.722 (um documento pode ter mais de um motivo): texto em inglês 2.258, linhas repetitivas 960, fora de escopo 360, pouco texto alfabético 256, curto demais 93, duplicatas 97
Dados pessoais mascarados	35.891: e-mail 19.859, CEP 9.279, telefone 5.861, outros 892

9.3 Produtos

Produto	Treino	Validação	Teste	Total
Pré-treino (documentos)	19.361	1.084	1.070	21.515
Fine-tuning (pares)	3.361	192	136	3.689
RAG (trechos)	—	—	—	1.000.330
Benchmark (itens)	—	—	—	775

A verificação final de dados pessoais encontrou 0 ocorrências nos 14 arquivos de produtos. A descontaminação não achou nenhum documento de treino parecido com os de avaliação.

10. Limitações

- O corpus tem o tamanho que o protocolo permite: a fila das instituições autorizadas acabou em ~25 mil PDFs. Crescer exigiria fontes fora da BDTD ou a reabilitação de instituições suspensas, e as duas frentes testadas esbarraram em veto explícito a robôs de IA (Oasisbr) ou em cobertura curta (CAPES).
- A UFRN (3.024 documentos) e a UFMG (2.845) somam 27% do corpus. A cobertura é desigual: há instituições fora por robots.txt, por falhas de servidor, por desafio anti-robô ou por sistemas que o coletor não reconhece.
- Nos documentos do inventário, que não têm resumo, o escopo é checado pelo começo do texto. Na amostra examinada em 13/09, cerca de 7 das 18 exclusões desses documentos eram de Saúde. Por exemplo, o sobrenome "Bezerra" casou com o termo de exclusão "bezerra", e "recursos hídricos" apareceu num estudo sobre dengue e clima. A regra não foi refinada e as 360 exclusões por escopo do corpus atual não foram revisadas uma a uma.
- O filtro por radicais também admite trabalhos de gestão e economia da saúde, como estudos sobre operadoras de planos de saúde.
- Os documentos do inventário chegam sem resumo, o que reduz os pares de fine-tuning.
- O recall da anonimização não foi medido, e quase-identificadores (idade, doença rara, município) não são tratados. Por isso o corpus não é declarado anonimizado.
- O fine-tuning por template de metadados e os benchmarks de recuperação não medem conhecimento de Saúde.
- Acesso aberto não é licença de redistribuição: os dados não são publicados nem entregues.