

Relatório — Atividade 02: pipeline de dados de teses e dissertações de Saúde

Grupo 7: Otávio da Conceição França, Ygor Moraes, Eduardo Melo

Disciplina: Tópicos em Inteligência Artificial (DC/CCN072) — UFPI — Prof. Raimundo Santos Moura

Data: 13/09/2026

Código: repositório bdt-d-corpus (este relatório está em docs/)

Como ler este relatório. As seções 1 a 6 explicam como o pipeline funciona, na ordem em que o dado passa por ele. A seção 7 mostra como a qualidade foi verificada e quais defeitos isso revelou. A seção 8 registra os incidentes e as perdas da coleta. A seção 9 traz os números finais, e a 10, as limitações. O protocolo de coleta completo está em docs/PROTOCOLO_DE_COLETA.md; aqui ele aparece resumido na seção 3.

Resumo

Construímos um pipeline em quatro camadas (Raw → Staging → Processed → Curated) que vai da coleta de teses e dissertações de Saúde até datasets de pré-treino continuado, fine-tuning, RAG e avaliação.

- **Coleta:** 3.596 PDFs de acesso aberto. 3.477 vêm da UFMG, pelo OAI-PMH; 119 vêm de um piloto com a UFRN e a Fiocruz, usando o inventário da BDTD exportado pelo grupo (183.718 fichas). A coleta respeita robots.txt, Crawl-delay e 1 requisição a cada 3 s por repositório. PUC-RS, UFSC e UFPR foram excluídas (veto a robôs de IA, desafio anti-robô e servidor fora do ar).
 - **Corpus final:** 2.951 documentos, 72,0 milhões de palavras, 3 instituições. Foram 4.937 ocorrências de dados pessoais mascaradas.
 - **Produtos:** pré-treino com 2.951 documentos (treino, validação e teste separados por autor + programa); 978 pares de fine-tuning tirados de campos verificáveis, sem LLM; 155.312 trechos para RAG; 784 itens de benchmark.
 - **Verificação final de dados pessoais no Curated: 0 ocorrências** nos 11 arquivos. Numa rodada anterior, essa mesma verificação parou o pipeline com erro e revelou um vazamento real (defeito 13).
 - **Qualidade:** 128 testes automáticos e leitura manual a cada rodada. A leitura achou 15 defeitos, quase todos invisíveis nas métricas, e todos foram corrigidos (seção 7). Entre eles: ~1.900 máscaras falsas que apagavam DOI e nome de gene, telefones reais escapando da anonimização, pares de fine-tuning com a resposta copiada na pergunta e 10 teses de Saúde excluídas como zootecnia.
 - **Perdas declaradas:** ~520 registros de uma janela da UFMG com falha no servidor; UFPR fora do ar. A meta de 20 mil PDFs não foi atingida nesta entrega (seção 10).
-

1. O enunciado e onde cada parte está

Item pedido	O que foi feito	Onde está no código
1. Crawler da BDTD para a área de Saúde	Inventário por OAI-PMH e pelo inventário da BDTD exportado pelo grupo; da página do item até o PDF; download com cota por estrato	src/raw/fontes.py, src/raw/inventario.py, src/raw/fulltext.py, src/raw/harvest.py
2. Arquitetura Raw → Staging → Processed → Curated	Quatro camadas; cada uma lê a anterior e nunca a modifica	src/raw/, src/staging/, src/processed/, src/curated/, run_pipeline.py
3. Processed: padronização, normalização, deduplicação e anonimização	Extração com OCR, normalização, padronização de metadados, anonimização com auditoria, filtros de qualidade e de escopo, deduplicação exata e aproximada	src/processed/
4. Curated: pré-treino continuado, fine-tuning, RAG e benchmarks	Quatro produtos, divisão por grupo, descontaminação e verificação final de dados pessoais	src/curated/

Tudo que é decisão de projeto (fontes, filtros, ritmo, limiares) está em config/config.yaml. Cada camada grava data/reports/saude/<camada>.json com entradas, saídas, métricas e falhas por tipo.

2. Visão geral

```
FONTES  OAI-PMH do repositório da UFMG + inventário da BDTD exportado pelo grupo
|
├─ RAW ..... guarda o que veio da fonte, sem mexer: metadado cru e PDF byte a byte
├─ STAGING ..... organiza: tabelas Parquet, codificação acertada, tipo real do arquivo
├─ PROCESSED ... trata: extrai o texto, limpa, padroniza, anonimiza, filtra, deduplica
└─ CURATED ..... entrega: pré-treino, fine-tuning (SFT), RAG, benchmarks + verificação de
PII
```

Por que camadas. Trocar um filtro ou corrigir um detector não exige baixar nada de novo: reprocessa-se a partir da camada afetada. Isso foi usado várias vezes neste trabalho (seção 7): todos os consertos de tratamento foram aplicados sobre os mesmos PDFs, sem nenhuma requisição nova.

Comandos.

```
python -m pytest # testes (nenhum toca em data/)
python preflight.py # antes de coletar; para se houver bloqueio
python -m src.raw.inventario construir # inventário pelas fontes OAI
python -m src.raw.inventario bdtc_csv # candidatos do inventário da BDTD
python run_pipeline.py --camadas raw # download (dentro do tmux)
```

3. Coleta (camada Raw)

3.1 A BDTD tem ficha, não tem PDF

A BDTD (IBICT) é um **agregador**: guarda a ficha de cada trabalho e aponta para o repositório da universidade, onde o PDF está. Toda coleta de texto tem, então, dois saltos: **(1) montar a lista** de trabalhos (inventário) e **(2) ir à página de cada trabalho no repositório de origem** e achar o PDF.

3.2 Montar a lista: duas fontes

Fonte 1 — OAI-PMH da UFMG (principal). OAI-PMH é o protocolo feito para máquinas colherem metadados de repositórios. Colhemos o conjunto `com_1843_6` (Ciências da Saúde) no formato `dim`, que preserva o campo "programa", e pedimos o formato `ore`, que já entrega o endereço do PDF.

- O DSpace da UFMG devolve erro HTTP 500 quando a paginação vai fundo; por isso a colheita é fatiada em janelas de datas (`janela_dias`).
- Uma janela que falha é **dividida ao meio**, até 1 dia; o que não se recupera é **declarado** no relatório (seção 8).
- **Disjuntor**: 5 falhas seguidas sem registro novo interrompem a colheita.

Fonte 2 — inventário da BDTD exportado pelo grupo. Eduardo Melo montou, no projeto G7-Atividade02-BDTD, o inventário da área inteira pela **API** da BDTD (`/vufind/api/v1/search`): 183.718 fichas com a URL do item no repositório de origem. O trabalho dele também documentou armadilhas da API, que registramos com o devido crédito:

- a paginação trava na página 10 (no máximo 1.000 registros por consulta);
- as facetas devolvem no máximo 30 valores;
- operador booleano dentro de `filter[]` devolve 0 resultados, sem erro.

A saída dele foi fatiar a consulta por prefixo do identificador. Reaproveitar o arquivo pronto **não gera nenhuma requisição nova à BDTD**. Sobre ele aplicamos os filtros deste projeto (`python -m src.raw.inventario btdt_csv`):

Filtro	Regra
Direitos	só acesso aberto com URL
Escopo (inclusão)	radicais sobre título e assuntos: <code>odontolog</code> pega "odontológico". <code>medic</code> e <code>hospital</code> não são usados: casam com "medição" e "hospitalidade" (uma tese de gastronomia tinha sido rotulada como de Saúde por isso)

Filtro	Regra
Escopo (exclusão)	vocabulário de zootecnia e veterinária, por palavra inteira
Instituições	exclui UFMG (já vem pelo OAI), UNIFESP (suspensa), PUC-RS e UFSC (seção 3.5)

Aplicado ao arquivo inteiro, o funil dá: 183.718 fichas → 160.801 com acesso aberto e link → 155.537 fora da UFMG → ~71 mil de Saúde pelos radicais.

3.3 Amostragem com cota por estrato

Cada candidato pertence a um **estrato** (instituição + faixa de 5 anos). O download percorre a fila de cada estrato até fechar a cota daquele estrato, e a taxa de sucesso de cada um vai para o relatório. Sem isso, estratos de repositórios que falham encolheriam em silêncio, e o viés ficaria invisível.

3.4 Da página do item até o PDF

`src/raw/fulltext.py` tenta, em ordem:

1. a metatag `citation_pdf_url` (padrão usado pelo Google Acadêmico; DSpace e TEDE emitem);
2. links `/bitstream/` ou `/bitstreams/` terminados em `.pdf`;
3. qualquer link `.pdf` da página;
4. **a API REST do DSpace 7** (`/server/api`): item → pacote ORIGINAL → primeiro PDF.

O item 4 e um ajuste no item 1 nasceram do diagnóstico do piloto (seção 8.3): a UFRN serve só a "casca" da página, sem nenhum link, e a Fiocruz publica a metatag com o endereço interno `http://localhost:4000/...`, que o coletor agora troca pelo domínio público da página.

O arquivo só é gravado se começar com `%PDF` (página de login ou de erro com HTTP 200 é descartada) e se tiver até 120 MB. O download é idempotente: rodar de novo não baixa o que já está no disco.

3.5 Conduta de rede (protocolo de coleta, resumido)

Regra	Como está implementada
Identificação	User-Agent com projeto, instituição e e-mail de contato
<code>robots.txt</code>	consultado e respeitado por domínio, inclusive crawl-delay , na colheita OAI e no download
Ritmo	1 requisição a cada 2 s na fonte de metadados; 1 a cada 3 s por repositório (ou o <code>Crawl-delay</code> , se maior). Repositórios diferentes andam em paralelo; dentro de um mesmo repositório o intervalo nunca diminui (o limitador reserva o próximo horário livre de cada domínio)

Regra	Como está implementada
Redirecionamento	seguido à mão: cada salto (<code>hdl.handle.net</code> → repositório final) passa pelo <code>robots.txt</code> e pelo ritmo do domínio de destino
Letra e espírito	quando divergem, vale o espírito. A busca da interface da BDTD (<code>Disallow: /vufind/Search/</code>) não é usada. A PUC-RS permite * mas proíbe nominalmente robôs de IA (GPTBot, ClaudeBot, CCBot...): foi excluída , porque o uso deste corpus é treino de modelo
Proteção anti-robô	motivo para parar, não para contornar: a UFSC responde <code>/robots.txt</code> com desafio do Cloudflare e foi excluída
Antes de coletar	<code>pytest + preflight.py</code> , que bloqueia sem contato, sem evidência de <code>robots.txt</code> de cada domínio ou com ritmo acima do protocolo
Critérios de parada	HTTP 429/500/503 persistente num domínio; bloqueio ou desafio anti-robô; contato de administrador; taxa de erro acima de 30% num domínio
Evidência	o <code>robots.txt</code> de cada domínio, como estava no dia, fica em <code>data/reports/saude/evidencia_robots_*.json</code>

A coleta roda dentro do `tmux`, para sobreviver à queda da sessão.

4. Staging

`src/staging/organize.py` transforma o JSONL cru em quatro tabelas Parquet (documentos, autores, assuntos, arquivos), corrige codificação, confere o tipo real de cada arquivo pelos primeiros bytes (e não pela extensão) e valida a integridade (hash, tamanho). Nada é descartado aqui: a Staging organiza, a Processed decide.

5. Tratamento (camada Processed)

extração → normalização → anonimização → qualidade → escopo → deduplicação
(+ padronização e anonimização do título e do resumo)

A ordem não é arbitrária. Filtrar antes de normalizar reprova documento bom por causa de codificação quebrada. Anonimizar antes de normalizar faz o detector de CPF errar por causa de hifenização e de espaços Unicode.

5.1 Extração

PyMuPDF página a página. Página quase sem texto é tratada como imagem; se a maioria das páginas for imagem, entra OCR (Tesseract, português). O número de páginas e de páginas com OCR vai para `extracao_stats.jsonl` e é reaproveitado quando o texto já está em cache.

5.2 Normalização

- **Caracteres:** `ftfy` (texto com codificação quebrada), forma Unicode NFC, ligaduras (`fi` → `fi`), caracteres de controle e espaços especiais.
- **Ruído de layout:** cabeçalho e rodapé repetidos entre páginas, número de página, hifenização de fim de linha, pontilhado de sumário.
- **Cortes:** tudo antes do RESUMO (capa, ficha catalográfica, agradecimentos) e o que vem depois das referências (anexos, onde ficam termos de consentimento assinados).

5.3 Padronização dos metadados

O mesmo campo chegava escrito de várias formas: o idioma aparecia como "Português" (1.879), "por" (1.727), "eng" (21), "Inglês", "fra" e "N/A". `src/processed/padroniza.py` leva cada campo a um vocabulário fechado e guarda o original ao lado (`<campo>_bruto`):

Campo	Padrão
idioma	código ISO: pt, en, es, fr...
tipo	dissertação de mestrado / tese de doutorado (legível, porque entra no texto das instruções do SFT)
ano	inteiro entre 1800 e o ano corrente; fora disso, vazio

5.4 Anonimização

Alvo: dados pessoais **de terceiros** no texto, no título e no resumo. Autor e orientador são dado bibliográfico público e não são anonimizados.

Detector	Regra
E-mail, perfil de rede social	padrão textual
CPF, CNPJ, título de eleitor, PIS/PASEP, cartão SUS	só com dígito verificador válido (título de eleitor com a regra do TSE e UF 01–28)
Telefone	DDD válido (sem zero), fixo começando com 2–5, celular com 9; intervalo de anos (2008–2009) recusado; quebra de linha aceita como separador só depois de (DD) ou +55 DD

Detector	Regra
CEP, RG	formato; RG com 7 a 10 dígitos
Links, DOI e ORCID	protegidos: ficam fora dos detectores numéricos
Placa de veículo	desligada

Cada máscara vai para `pii_relatorio.parquet` com o trecho em volta **já mascarado**, para que alguém confira à mão sem expor o dado.

Precisão medida, não presumida. Na primeira versão, recuperamos o valor original por trás de cada máscara (comparando com o texto antes da limpeza) e descobrimos que a maioria dos alarmes de alguns detectores era falsa:

Detector	Máscaras antes → depois	O que era de verdade
Título de eleitor	863 → 0	ORCID (0000-0002-8214) e DOI
Placa	478 → 0 (desligada)	gene CYP2C19; sigla + ano de estudo: OMS-2008, GBD-2017
Cartão SUS	266 → 1	DOI e código de setor censitário do IBGE
PIS/PASEP	257 → 8	DOI da revista Ciência & Saúde Coletiva
Telefone	580 → 394	quase todo real (comitê de ética, contato de pesquisador)

Mascarar um DOI ou um nome de gene destrói conteúdo científico sem proteger ninguém. Por isso a precisão foi corrigida **antes** de ampliar a coleta e antes de ligar a verificação que para o pipeline (senão ela pararia por alarme falso).

5.5 Qualidade e escopo

- **Qualidade:** heurísticas no estilo Gopher/RefinedWeb, calibradas para tese em português: tamanho, proporção de texto alfabético e de símbolos, tamanho médio de palavra, stopwords, linhas repetidas, tokens curtos (sinal de OCR de tabela) e idioma por votação em três janelas do meio do texto. O motivo de cada reprovação fica registrado.
- **Escopo:** exclusão de zootecnia e veterinária por palavra inteira, sobre título, programa, assuntos e resumo (ou o começo do texto, quando não há resumo). A checagem roda de novo aqui, para que uma lista corrigida valha para o que já foi baixado. Antes da comparação, **expressões permitidas** são apagadas do texto: "pé equino", "soro fetal bovino", "dentina bovina" são Saúde, não zootecnia (defeito 15).

5.6 Deduplicação

- **Exata:** SHA-256 do texto normalizado.

- **Aproximada:** MinHash + LSH, similaridade de Jaccard $\geq 0,80$.
- **Interna:** parágrafo repetido dentro do mesmo documento.

6. Produtos (camada Curated)

Produto	Formato	Para quê
pretreino/*.jsonl	{id, text, meta}	pré-treino continuado de um modelo aberto já existente
sft/*.jsonl	{id, messages, meta}	fine-tuning para seguir instruções
rag/corpus_rag.parquet	trechos de 500 palavras com sobreposição de 50 e metadado	busca semântica com citação da fonte
benchmark/	recuperação, múltipla escolha, perplexidade + instruções de pontuação	avaliação
indice_corpus.parquet, DATACARD.md	índice e ficha do corpus	documentação

- **Divisão por grupo:** treino, validação e teste são separados por autor + programa, e o treino é **descontaminado** contra a avaliação por MinHash.
- **SFT sem modelo gerador:** os pares vêm de campos verificáveis do próprio documento (resumo, título, palavras-chave e a introdução do texto). Nenhuma resposta é inventada por um LLM. Texto em inglês não entra nem na pergunta nem na resposta.
- **Metadados tratados:** título e resumo usados no SFT e no benchmark vêm da Processed, já padronizados e anonimizados.
- **Campo fonte honesto:** diz se o documento veio do OAI-PMH ou do inventário da BDTD, e de qual repositório.
- **RAG gravado em lotes:** montar ~150 mil trechos na memória derrubava o processo.
- **Verificação final de dados pessoais** (src/curated/verificar_pii.py): varre todos os produtos com os mesmos detectores; se encontrar qualquer ocorrência, grava verificacao_pii_curated.json e o run_pipeline.py **sai com erro**.
- **O que os benchmarks medem:** recuperação e memória sobre o acervo, **não** domínio do conteúdo de Saúde. Isso exigiria perguntas escritas e revisadas por especialistas.

7. Como a qualidade foi verificada

7.1 Testes automáticos

128 testes (python -m pytest, ~4 s), todos em diretório temporário: nenhum toca em data/. Cada defeito

corrigido ganhou um teste com o caso real que o revelou (o código de procedimento 0101020058, o gene CYP2C19, a "catequina", a página-casca da UFRN, o localhost:4000 da Fiocruz...). Os testes que acessam "rede" usam servidor e sessão simulados.

7.2 Leitura manual

Regra do projeto: **métrica boa não é prova**. A cada reproprocessamento foram lidos textos tratados, pares de SFT e amostras do pii_relatorio.parquet. A maioria dos defeitos abaixo foi achada assim. Os outros vieram de teste automático, da verificação final ou de uma métrica incoerente. Nenhum apareceu como uma métrica de qualidade ruim.

7.3 Defeitos achados e corrigidos

#	Defeito	Como apareceu	Correção
1	Teses de zootecnia no corpus ("nutrição" casa com nutrição animal)	leitura de títulos	lista de exclusão aplicada também ao resumo
2	Filtro de acesso aberto não aplicado no caminho OAI: 16 documentos de acesso restrito quase entraram	leitura do manifesto	filtro no harvest.py
3	Zootecnia de novo: a lista só tinha plural masculino, e doença animal concorda no feminino ("raiva bovina")	leitura de títulos	todas as flexões; checagem repetida na Processed
4	Máscaras falsas: código de procedimento virando telefone, PEG6000 virando placa, eixo de anos virando título de eleitor	leitura de textos	separador obrigatório; formato de placa estrito
5	Texto de rodada anterior reaprovaado em silêncio	leitura do relatório	Processed restrita ao Staging atual
6	Páginas e OCR zerados quando o texto vinha do cache	métrica incoerente	histórico extracao_stats.jsonl
7	RAG estourando memória	processo morto 2 vezes	gravação em lotes
8	~1.900 máscaras falsas (DOI, ORCID, gene)	valor original recuperado atrás de cada máscara	dígito verificador, proteção de links, placa desligada (seção 5.4)

#	Defeito	Como apareceu	Correção
9	Exclusão por trecho de palavra: "equina" casava dentro de "catequina"	teste automático	exclusão por palavra inteira
10	Título e resumo iam para o SFT sem anonimização ; resumo em inglês dentro da pergunta	revisão do código da Curated	metadados.parquet anonimizado; trava de idioma na pergunta
11	No par "resuma", a resposta vinha copiada dentro da pergunta : o texto começa no RESUMO	leitura de pares de SFT	trecho tirado de depois do resumo; par descartado se houver sobreposição
12	Coletor não achava PDF em DSpace 7 sem renderização no servidor (UFRN) nem com metatag apontando para localhost (Fiocruz)	piloto com 0 de 180	API REST do DSpace 7; troca do endereço interno
13	Telefone real quebrado em linha depois do DDD ((31) 43xxxx-xxxx) escapava da anonimização; e o RAG, ao juntar linhas com espaço, criava "telefones" e "CPFs" a partir de tabelas	a verificação final do Curated parou o pipeline com erro (35 ocorrências, todas no RAG)	quebra de linha aceita só depois de (DD) ou +55 DD; o RAG recorta o texto original, com as quebras. Auditoria da regra nova sobre os textos já tratados: 17 telefones a mais, todos reais
14	O conserto do defeito 11 criou outro: o trecho "depois do resumo" era o ABSTRACT (109 de 178 pares viraram tradução disfarçada), e a trava de idioma não via, porque "a", "as", "do" e "no" também são palavras inglesas	leitura de pares de SFT depois do reprocessamento	trecho a partir do título INTRODUÇÃO do corpo; trava compara português com inglês; palavras-chave sem código CNPQ: :. No corpus real: 219 pares, 0 cópias, 1 em inglês
15	10 teses de Saúde excluídas como zootecnia : "saneamento" (saúde pública, 4 da Fiocruz), "pé equino" (ortopedia infantil), dentina bovina (odontologia in vitro, 2), soro fetal bovino, albumina sérica bovina e tripsina bovina (reagentes)	revisão à mão dos 42 excluídos, puxada por documentos da Fiocruz que não deviam ter saído	"saneamento" sai da lista; lista de expressões permitidas , apagadas do texto antes da checagem, na colheita e na Processed. Voltaram 8 ao corpus; as 2 de odontologia seguem fora por estarem em inglês

O defeito 15 corrige uma afirmação anterior deste próprio trabalho. Os 39 excluídos da 3ª rodada tinham sido dados como "todos zootecnia" a partir dos títulos. Só a leitura do termo que derrubou cada documento mostrou os falsos. Ficaram excluídos, como casos de fronteira declarados, 2 estudos de vaccinia bovina

(vírus de gado que infecta ordenhadores) e 1 de doenças vesiculares de bovinos.

O defeito 13 é o melhor argumento a favor da verificação final. O vazamento existia também no pré-treino, mas lá a quebra de linha escondia o número dos detectores. Só o RAG, que juntava as linhas, o deixou visível, e a verificação barrou a entrega em vez de deixá-lo passar.

8. Incidentes e perdas declaradas

O registro completo, com data, número de requisições e evidência, está na seção 8 do protocolo. Resumo:

8.1 Janela de datas perdida na UFMG

Os registros com data entre 25/02/2026 e 25/06/2026 dão HTTP 500 no formato dim, em qualquer recorte, até 1 dia.

- **Diagnóstico** (~10 requisições): a janela tem **755 registros**. No formato oai_dc a primeira página responde, mas a paginação volta a falhar.
- **Recuperação**: 235 registros → 13 de Saúde → **4 candidatos novos**. O disjuntor interrompeu sozinho após 5 falhas seguidas.
- **Perda declarada**: ~520 registros não colhidos (~50 de Saúde, pela proporção do resto da coleta), listados em data/reports/saude/inventario_janela.json.

8.2 Piloto 1: instituições excluídas antes de baixar

A leitura do robots.txt excluiu duas instituições: a PUC-RS (veta robôs de IA) e a UFSC (desafio anti-robô do Cloudflare). O download foi interrompido antes de gravar qualquer arquivo, e o inventário foi restaurado sem elas.

8.3 Piloto 2: 0 de 180 PDFs

UFRN, UFPR e Fiocruz, 60 candidatos cada: **nenhum PDF**. Pelo critério de parada (taxa de erro acima de 30% num domínio), a expansão não seguiu. O diagnóstico (1 registro por instituição, ~15 requisições, sem baixar PDF; data/reports/saude/diagnostico_piloto_btdt.json) achou três causas diferentes:

Instituição	Sintoma	Causa	Decisão
UFRN	pdf_ao_nao_localizado	Dspace 7 sem renderização no servidor: a página tem 1 KB e nenhum link	coletor passa a usar a API REST do DSpace 7
Fiocruz	bloqueado_ou_erro_rede	a metatag aponta para http://localhost:4000/bitstreams/.../download (configuração do servidor deles)	endereço interno trocado pelo domínio público
UFPR	pdf_ao_nao_localizado	hdl.handle.net/1884/... responde "Cannot	retirada : não se

Instituição	Sintoma	Causa	Decisão
		Connect to Server" (HTTP 500): o servidor de handles da UFPR está fora do ar	insiste em serviço que está falhando

8.4 Piloto 3: mesmos candidatos, depois da correção

Com o coletor corrigido e a UFPR retirada, os **mesmos 120 candidatos** foram tentados de novo (nenhum candidato novo; testes e `preflight.py` antes):

Instituição	Piloto 2	Piloto 3
UFRN (DSpace 7, via API REST)	0 / 60	60 / 60
Fiocruz (DSpace 7, metatag corrigida)	0 / 60	59 / 60
UFPR (servidor de handles fora do ar)	0 / 60	retirada

Foram 473 MB em 22 minutos, sem nenhum erro de rede. A UFRN custa ~5 requisições por trabalho (página + API), no ritmo de 1 a cada 3 s. A lição para a expansão: **cada família de repositório precisa ser pilotada antes**. Um coletor que funciona em 3.477 PDFs da UFMG deu 0 em três repositórios diferentes.

8.5 Outras

- **UNIFESP suspensa** desde a 1ª rodada: uma versão antiga do coletor não respeitava o `Crawl-delay: 15`; depois, conexão recusada.
- **Anhembi**: 2 links testados à mão pelo grupo não carregaram. A instituição tem 1 ficha no conjunto filtrado e não foi incluída no piloto.

9. Resultados

9.1 Coleta (Raw e Staging)

Fonte	Candidatos	Bloqueados por direitos	PDFs obtidos
UFMG, OAI-PMH (3ª rodada + 4 da janela recuperada)	3.636	186	3.477
Inventário da BDTD — UFRN (piloto)	60	—	60
Inventário da BDTD — Fiocruz (piloto)	60	—	59

Fonte	Candidatos	Bloqueados por direitos	PDFs obtidos
Total	3.756	186	3.596

O Staging organizou os 3.756 registros, 3.582 deles com arquivo. Os 14 arquivos de rodadas anteriores sem registro atual foram apontados e ignorados.

9.2 Tratamento (Processed)

Instituição	Textos tratados	No corpus final
UFMG	3.463	2.845
UFRN	60	52
Fiocruz	59	54
Total	3.582	2.951

- **72,0 milhões de palavras**; mediana de 20.546 palavras por documento; 340.069 páginas; 58 documentos precisaram de OCR.
- **Reprovados (631)**: 628 por qualidade ou escopo e 3 duplicatas exatas; nenhuma duplicata aproximada. Os motivos mais comuns (um documento pode ter mais de um):

Motivo	Documentos
texto em inglês	445
linhas repetitivas (tabela, OCR ruim)	150
pouco texto alfabético	42
fora de escopo (zootecnia/veterinária)	32
OCR fragmentado	11
outros idiomas	7

- **Dados pessoais mascarados**: 4.937 ocorrências, todas no texto (título e resumo não tinham nenhuma): e-mail 2.992, CEP 1.244, telefone 626, CPF 27, PIS/PASEP 24, perfil de rede social 19, CNPJ 4, cartão SUS 1.

9.3 Produtos (Curated)

Produto	Treino	Validação	Teste	Total
Pré-treino (documentos)	2.652	150	149	2.951
Fine-tuning (pares)	882	55	41	978
RAG (trechos de 500 palavras)	—	—	—	155.312
Benchmark: recuperação / múltipla escolha / perplexidade	—	—	—	292 / 292 / 200

- **Descontaminação:** nenhum documento de treino colidiu com a avaliação.
- **Pares de fine-tuning por tipo:** título a partir do resumo 267; explicação do trabalho a partir do título 265; resumo a partir do tema 167; resumo a partir da introdução 220; palavras-chave 59.
- **Conferência dos pares de resumo:** nenhuma resposta copiada na pergunta e 1 pergunta em inglês, contra 186 cópias e 109 abstracts nas versões anteriores.
- **Documentos do piloto no fine-tuning:** 30 pares, todos de palavras-chave da Fiocruz (sem resumo, os outros tipos não se aplicam). As palavras-chave vêm como o repositório as declara, misturando português, inglês e espanhol.
- **Verificação final de dados pessoais:** 0 ocorrências nos 11 arquivos (pré-treino, fine-tuning, RAG, benchmarks e índice), com os mesmos detectores da Processed (data/reports/saude/verificacao_pii_curated.json).

10. Limitações e trabalho futuro

- **A meta de 20 mil PDFs não foi atingida.** A expansão depende de nova autorização de coleta e, pelo piloto, de adaptar o coletor a cada família de repositório. Com o ritmo do protocolo (1 requisição a cada 3 s por repositório) e ~71 mil candidatos, a estimativa é de dezenas de horas por repositório grande, em paralelo entre repositórios.
- **Poucas instituições.** O corpus fala pela produção da UFMG (e das instituições do piloto), não pela área no país.
- **Documentos do inventário da BDTD chegam sem resumo e sem programa** (o arquivo não traz esses campos) e com a instituição como sigla. Eles entram no pré-treino e no RAG, mas quase não geram pares de SFT (que dependem do resumo), e o escopo deles é checado pelo começo do texto. Buscar o resumo na API do repositório custaria mais requisições por documento.
- **Recall da anonimização não medido.** Precisão foi medida e corrigida. A leitura do relatório mostrou telefones que escapam, escritos sem hífen ((31) 3xxxxxxx) ou com 0xx no DDD. Medir recall exige uma amostra rotulada à mão.
- **Quase-identificadores** (idade + doença rara + município + ano) permitem reidentificação sem nenhum CPF ou nome, e nenhum detector automático resolve isso. O corpus **não é declarado anonimizado**: declara-se o que foi detectado e mascarado.
- **Janela da UFMG:** recuperar os ~520 registros um a um (GetRecord) de um servidor que está falhando ficou para depois, com aviso ao administrador.
- **UFPR:** mapear o handle direto para o repositório (sem passar pelo servidor de handles) exige

verificar o robots.txt desse outro domínio.

- **O fine-tuning é gerado por template de metadado** (título, resumo, palavras-chave, introdução), não por perguntas e respostas sobre o corpo do texto. Ensina o formato de instrução, não conteúdo profundo; perguntas de conteúdo exigiriam geração com revisão humana.
 - **Benchmarks** medem recuperação, não conhecimento de Saúde.
 - **Direitos autorais:** acesso aberto não é licença de redistribuição. Os dados não são publicados nem entregues; só código, relatórios e ficha do corpus.
-

11. Créditos

- **Eduardo Melo** (projeto G7-Atividade02-BDTD): inventário da BDTD da área de Saúde pela API (183.718 fichas) e documentação das armadilhas da API, reaproveitados como fonte 2 deste pipeline.
- **Grupo 7** — Otávio da Conceição França, Ygor Moraes, Eduardo Melo.