

Relatório — Atividade 02: pipeline de dados de teses e dissertações de Saúde

Grupo 7: Eduardo Melo, Otávio França e Ygor Moraes
Disciplina: Tópicos em Inteligência Artificial (DC/CCN072) — UFPI — Prof. Raimundo Santos Moura
Data: 13/09/2026
Código: repositório bdttd-corpus. O protocolo de coleta completo está em docs/PROTOCOLO_DE_COLETA.md.

Resumo

O grupo construiu um pipeline em quatro camadas (Raw → Staging → Processed → Curated). Ele coleta teses e dissertações de Saúde e as transforma em dados para pré-treino continuado, fine-tuning, RAG e avaliação de modelos de linguagem em português.

- **Coleta:** 15.098 PDFs de acesso aberto, de 62 instituições, pelo OAI-PMH da UFMG e pelo inventário da BDTD (183.718 fichas). A coleta respeita o robots.txt pela letra e pelo espírito, no ritmo de 1 requisição a cada 3 segundos por repositório.
- **Corpus tratado:** 2.951 documentos (72,0 milhões de palavras), a partir dos primeiros 3.596 PDFs, com 4.937 dados pessoais mascarados.
- **Produtos:** pré-treino com 2.951 documentos, 978 pares de fine-tuning, 155.312 trechos para RAG e 784 itens de benchmark. A verificação final de dados pessoais encontrou 0 ocorrências.
- **Qualidade:** 156 testes automáticos e 21 defeitos corrigidos, a maioria achada por leitura manual dos dados.
- **Limites:** a coleta parou em 15.098 PDFs pelo prazo; a meta era 20 mil. Os PDFs coletados além dos primeiros 3.596 ainda não passaram pelo tratamento.

1. Enunciado e onde está no código

Item pedido	Implementação	Código
Crawler da BDTD para Saúde	inventário por OAI-PMH e pelo inventário da BDTD; página do item até o PDF; download por instituição	src/raw/
Arquitetura em camadas	Raw → Staging → Processed → Curated; nenhuma camada altera a anterior	src/, run_pipeline.py
Tratamento na Processed	extração com OCR, normalização, padronização, anonimização, qualidade, escopo e deduplicação	src/processed/
Produtos na Curated	pré-treino, fine-tuning, RAG, benchmarks e verificação de dados pessoais	src/curated/

As decisões de projeto (fontes, filtros, ritmo, limiares) ficam em config/config.yaml. Cada camada grava um relatório com entradas, saídas, métricas e falhas em data/reports/saude/.

2. Arquitetura

FONTES	OAI-PMH da UFMG + inventário da BDTD
— RAW	metadado cru e PDF original, sem alteração
— STAGING	tabelas Parquet, codificação corrigida, tipo real do arquivo
— PROCESSED	extração, limpeza, padronização, anonimização, filtros, dedup
— CURATED	pré-treino, fine-tuning, RAG, benchmarks, verificação de PII

Nenhuma camada modifica a anterior. Por isso, corrigir um filtro exige apenas reprocessar a partir da camada afetada, sem baixar nada de novo.

```
python -m pytest # testes
python preflight.py # verificação antes de coletar
python -m src.raw.inventario robots # evidência de robots.txt por domínio
python -m src.raw.inventario bdttd_csv # candidatos do inventário da BDTD
python run_pipeline.py --camadas raw # download
python run_pipeline.py --camadas staging processed curated
```

3. Coleta (Raw)

3.1 Fontes

A BDTD guarda as fichas dos trabalhos, mas o PDF fica no repositório de cada universidade. Por isso a coleta tem dois passos: montar a lista de trabalhos e, para cada um, achar o PDF no repositório de origem.

- **OAI-PMH da UFMG** (conjunto de Ciências da Saúde). A colheita é fatiada em janelas de datas, porque a paginação profunda do servidor falha. Uma janela que falha é dividida ao meio; se não se recuperar, a perda é declarada.
- **Inventário da BDTD**, montado pelo grupo pela API da BDTD (183.718 fichas). A busca da interface, proibida a robôs, não é usada. A API tem limites que exigiram fatiar a consulta: a paginação para na página 10 e as facetadas devolvem no máximo 30 valores. Sobre o inventário aplicam-se os filtros do projeto: acesso aberto; escopo de Saúde por radicais ("odontolog" pega "odontológico"); exclusão de zootecnia e veterinária por palavra inteira; e até 800 candidatos sorteados por instituição.

3.2 Da página do item ao PDF

O coletor tenta, nesta ordem:

1. a metatag `citation_pdf_url`;
2. os links de arquivo da página;
3. nos repositórios DSpace 7 que entregam a página sem links, a API REST do próprio repositório, com o endereço lido de `assets/config.json`.

O coletor também corrige endereços internos publicados por engano, como `localhost` ou IP com porta 4000. Só grava arquivos que começam com `%PDF` e têm até 120 MB. O download é retomável: um PDF que já está no disco não gera nova requisição.

3.3 Conduta de rede

Regra	Implementação
Identificação	User-Agent com projeto, instituição e e-mail de contato

Regra	Implementação
Ritmo	1 requisição a cada 3 s por repositório, ou o Crawl-delay, se maior; até 24 instituições em paralelo, sem acelerar nenhum domínio
robots.txt	respeitado em todos os caminhos de rede e em cada redirecionamento
Letra e espírito	fica fora o domínio que veta robôs de IA pelo nome, que responde com desafio anti-robô ou que bloqueia o nosso agente. A checagem é feita antes da coleta e, nos links de handle, no domínio final
Crítérios de parada	disjuntor por instituição (erro acima de 30% após 20 tentativas); na colheita OAI, 5 falhas seguidas
Antes de coletar	testes e preflight, que bloqueiam a coleta sem evidência de robots.txt por domínio ou com ritmo acima do protocolo
TLS	verificação de certificado nunca desligada

4. Staging

A Staging converte o JSONL cru em quatro tabelas Parquet (documentos, autores, assuntos e arquivos), corrige a codificação, confere o tipo real de cada arquivo pelos primeiros bytes e valida a integridade. Nada é descartado nessa camada.

5. Tratamento (Processed)

As etapas seguem esta ordem: extração → normalização → anonimização → qualidade → escopo → deduplicação. A ordem importa: filtrar antes de normalizar reprova documento com codificação quebrada, e anonimizar antes de normalizar faz o detector de CPF errar.

- **Extração:** PyMuPDF, com OCR (Tesseract, português) quando a maioria das páginas é imagem.
- **Normalização:** codificação (ftfy), Unicode NFC, ligaduras, cabeçalhos e rodapés repetidos, números de página e hifenização. Também corta tudo antes do RESUMO e os anexos.
- **Padronização:** idioma em código ISO, tipo como "dissertação de mestrado" ou "tese de doutorado" e ano como inteiro, com o valor original preservado.
- **Anonimização** de dados de terceiros no texto, no título e no resumo. Autor e orientador não são mascarados, porque são dado bibliográfico público.

Detector	Regra
E-mail e perfil de rede social	padrão textual
CPF, CNPJ, título de eleitor, PIS/PASEP e cartão SUS	só com dígito verificador válido
Telefone	DDD válido, fixo começando de 2 a 5, celular com 9; intervalo de anos recusado
CEP e RG	formato; RG com 7 a 10 dígitos
Links, DOI e ORCID	protegidos dos detectores numéricos

Cada máscara é registrada com o trecho em volta já mascarado. A precisão foi medida recuperando o valor por trás de cada máscara: ~1.900 eram falsas (DOI e ORCID tomados por documento, nome de

gene tomado por placa) e foram eliminadas.

- **Qualidade:** heurísticas no estilo Gopher/RefinedWeb, calibradas para tese em português: proporção de texto, símbolos, stopwords, linhas repetidas e idioma.
- **Escopo:** exclusão de zootecnia e veterinária por palavra inteira, com uma lista de expressões permitidas, como "pé equino" e "soro fetal bovino".
- **Deduplicação:** exata (SHA-256) e aproximada (MinHash com LSH, Jaccard a partir de 0,80).

6. Produtos (Curated)

Produto	Formato	Uso
Pré-treino	JSONL com id, texto e metadados	pré-treino continuado de modelo existente
Fine-tuning	JSONL com mensagens e metadados	seguir instruções
RAG	Parquet, trechos de 500 palavras com metadados	busca com citação da fonte
Benchmark	recuperação, múltipla escolha e perplexidade	avaliação

- Treino, validação e teste são divididos por autor e programa, e o treino é descontaminado contra a avaliação.
- Os pares de fine-tuning saem de campos do próprio documento (título, resumo, palavras-chave e introdução), sem texto gerado por modelo. Texto em inglês não entra.
- A **verificação final de dados pessoais** varre todos os produtos e interrompe o pipeline com erro se encontrar qualquer ocorrência.
- Os benchmarks medem recuperação sobre o acervo, não conhecimento de Saúde.

7. Verificação de qualidade

O projeto tem **156 testes automáticos** (`python -m pytest`), que não acessam a rede nem os dados reais. Cada defeito corrigido ganhou um teste com o caso real que o revelou. A cada reprocessamento, o grupo leu textos tratados, pares de fine-tuning e amostras das máscaras de dados pessoais. No total, 21 defeitos foram corrigidos; os principais estão abaixo.

Área	Defeito	Correção
Escopo	teses de zootecnia no corpus e, no sentido oposto, 10 teses de Saúde excluídas por "saneamento" ou "pé equino"	exclusão por palavra inteira, com todas as flexões e expressões permitidas
Anonimização	~1.900 máscaras falsas sobre DOI, ORCID e nomes de gene	dígito verificador e proteção de links
Anonimização	telefone real quebrado em linha escapava; foi achado porque a verificação final parou o pipeline	quebra de linha aceita depois do DDD
Fine-tuning	resposta copiada na pergunta (186 pares) e, depois, abstract em inglês no lugar do trecho (109 pares)	trecho tirado da introdução e trava de idioma
Direitos	16 documentos de acesso restrito quase entraram no corpus	filtro de acesso aberto em todos os caminhos

Área	Defeito	Correção
Coleta	repositórios DSpace 7 sem PDF localizável e endereços internos publicados	API REST com endereço do config.json e troca do endereço interno
Coleta	paralelismo travava num mesmo domínio; o disjuntor cortava instituições boas ao retomar	paralelismo por instituição e disjuntor com histórico
Processamento	o RAG estourava a memória; texto de rodada anterior era reaprovaado	gravação em lotes e Processsed restrita ao Staging atual

8. Incidentes e perdas

Evento	O que houve	Decisão
Janela de datas da UFMG (fevereiro a junho de 2026)	o servidor responde HTTP 500; dos 755 registros, 235 foram recuperados	~520 registros declarados como perdidos
Piloto do inventário (UFRN, UFPR, Fiocruz)	0 de 180 PDFs, por variações de DSpace 7 e pelo servidor de handles da UFPR fora do ar	coletor corrigido (119 de 120 na repetição); UFPR fora
robots.txt de 179 domínios	21.253 de 35.238 candidatos autorizados	saíram por inacessibilidade (6.495), HTTP 403, 468 ou 5xx (4.616), veto a robôs de IA (2.641), bloqueio total (187) e desafio anti-robô (46)
Disjuntor na coleta em escala	26 instituições cortadas na primeira execução	7 defeitos do coletor corrigidos; 23 instituições com falha confirmada (certificado inválido, handle fora do ar, desafio anti-robô, links quebrados) suspensas sem nenhuma requisição
Prazo de entrega	meta de 20 mil PDFs	coleta parada em 15.098 PDFs

9. Resultados

9.1 Coleta

Etapas	PDFs
UFMG pelo OAI-PMH	3.477
Piloto do inventário (UFRN e Fiocruz)	119
Coleta em escala pelo inventário	11.502
Total	15.098

Os PDFs vêm de 62 instituições. Além da UFMG, as que mais contribuíram foram Fiocruz (842), UFS e UNESP (800 cada), UFU (797), UFG (704), UFSCar (702), UFV (700) e UFRN (697).

9.2 Corpus tratado (primeiros 3.596 PDFs)

Métrica	Valor
Documentos no corpus	2.951 (UFMG 2.845, Fiocruz 54, UFRN 52)
Palavras	72,0 milhões (mediana de 20.546 por documento)
Reprovados	631: texto em inglês 445, linhas repetitivas 150, pouco texto 42, fora de escopo 32, duplicatas 3
Dados pessoais mascarados	4.937: e-mail 2.992, CEP 1.244, telefone 626, outros 75

9.3 Produtos

Produto	Treino	Validação	Teste	Total
Pré-treino (documentos)	2.652	150	149	2.951
Fine-tuning (pares)	882	55	41	978
RAG (trechos)	—	—	—	155.312
Benchmark (itens)	—	—	—	784

A verificação final de dados pessoais encontrou 0 ocorrências nos 11 arquivos de produtos.

10. Limitações

- A coleta parou em 15.098 PDFs pelo prazo. O tratamento e os produtos correspondem aos primeiros 3.596 PDFs; os demais estão coletados e podem ser reprocessados sem nova requisição.
- A cobertura é desigual: há instituições fora por robots.txt, por falhas de servidor ou por sistemas que o coletor não reconhece (Tainacan, JSF).
- Os documentos do inventário chegam sem resumo, o que reduz os pares de fine-tuning.
- O recall da anonimização não foi medido, e quase-identificadores (idade, doença rara, município) não são tratados. Por isso o corpus não é declarado anonimizado.
- O fine-tuning por template de metadados e os benchmarks de recuperação não medem conhecimento de Saúde.
- Acesso aberto não é licença de redistribuição: os dados não são publicados nem entregues.